W-1 SQL 검색기

> 상담사 질문을 정해 둔 조회(정형쿼리) 또는 LLM이 만든 SQL(NL2SQL)로 바꿔,
> 회원 범위 안에서만 안전하게 답을 찾음

워크플로우	팀명	작성일
W-1 SQL 검색기	design-agentic-ai	2026-10-15

무단전재 및 배포 금지

설계 개요

정형 DB에서 답을 찾는 동기 요청 1건을 15초 안에 끝내는 워크플로우를 설계함

설계 대상과 범위

- 설계 대상: SQL 검색기 워크플로우 W-1(단계 6개, 반복 구간 1개, 커넥터 1개)
- 관련 유저스토리: 없음
- 시작 트리거: 동기 요청(호출자가 검색을 요청하고 응답을 기다림) → 단계ID 접두어 S-R
- 설계 범위: 요청 검증, 정형쿼리 또는 NL2SQL 판단, 계획 판정, SQL 검증, SQL 실행, 응답 반환
- 제외 범위: 답변 문장 생성(호출자 몫), 비정형 문서 검색(RAG), DB 스키마와 뷰 변경

설계 기준

1. DB 취급: 시스템 내부 구성요소. 외부시스템 연동 명세와 커넥터 목록에 넣지 않음
2. 전체 시간 예산: 15초(종료 처리 시간 1초)
3. 필드 표기 방식: 이름(타입, 필수 여부, 설명). 타입은 string, integer, boolean, date(YYYY-MM-DD), datetime, object, array
4. DB 계정: NL2SQL 실행 계정 sql_retriever_user(관리자 권한 없음, 읽기 전용 세션)

무단전재 및 배포 금지

처음 보는 분을 위한 용어 풀이

설계서에 자주 나오는 용어를 한 줄로 풀어 둠

용어

용어	한 줄 풀이
NL2SQL	사람이 쓴 질문(Natural Language)을 LLM이 DB 조회 문장(SQL)으로 바꾸는 방식
정형쿼리	자주 묻는 질문에 쓰려고 미리 만들어 검사까지 끝낸 고정 SQL. ID로 골라 씀
뷰(View)	원본 표를 그대로 보여 주지 않고, 필요한 컬럼과 기간만 골라 보여 주는 가상의 표
행 수준 보안(RLS)	DB가 행마다 "이 회원의 행인가"를 검사해, 지정한 회원의 행만 보이게 거르는 기능
세션 변수	DB 접속 하나에만 잠시 붙여 두는 값. 여기서는 회원ID, 기준일, 거래 제공 시작일
최악값	타임아웃까지 기다리고 재시도까지 다 썼을 때 걸리는 가장 긴 시간
반복 구간	결과가 기준에 못 미칠 때 앞 단계로 되돌아가 다시 도는 구간
착지 단계	시간이 모자라거나 재시도를 다 썼을 때 이어서 가는 단계

무단전재 및 배포 금지

목차

설계 가이드의 작성 순서 ① ~ ⑥을 따라 구성함

1 단계 도출 및 순서 정의

단계 목록, 흐름 도식, Mermaid

2 단계별 명세

S-R1 ~ S-R6 단계마다 2장

3 외부시스템 연동 명세

Groq LLM 연동과 초과 시 처리

4 반복 구간 명세

L-1 재계획 구간

5 워크플로우 명세

최악값 합계와 시간 예산 대조

C 커넥터 설계

목록, LLM 명세, 프롬프트, 응답 구조

6 남은 시간 예산 정책

측정 시점, 계산 예, 착지

+ 부록

뷰, 정형쿼리, 검증 규칙, 필드, 오류, 점검표

무단전재 및 배포 금지

① 단계 목록과 흐름 유형

입력 워크플로우 6단계를 그대로 쓰고, 검증 실패 시 되돌아가는 반복 구간 1개를 둠

단계ID	단계명	담당자 유형	흐름
S-R1	검색 요청 접수와 검증	규칙기반 코드	순차
S-R2	정형쿼리 또는 NL2SQL 판단	생성형AI + 규칙기반 코드	순차(반복 구간 시작)
S-R3	계획 적합성 판정	규칙기반 코드	분기(적합, 부적합, 답할 수 없음)
S-R4	SQL 검증	규칙기반 코드	분기(통과, 재생성, 오류 종료)
S-R5	SQL 실행	규칙기반 코드	순차(실패 시 오류 종료)
S-R6	응답 구성과 반환	규칙기반 코드	합류(S-R5, S-R3)

흐름 유형 판단 이유

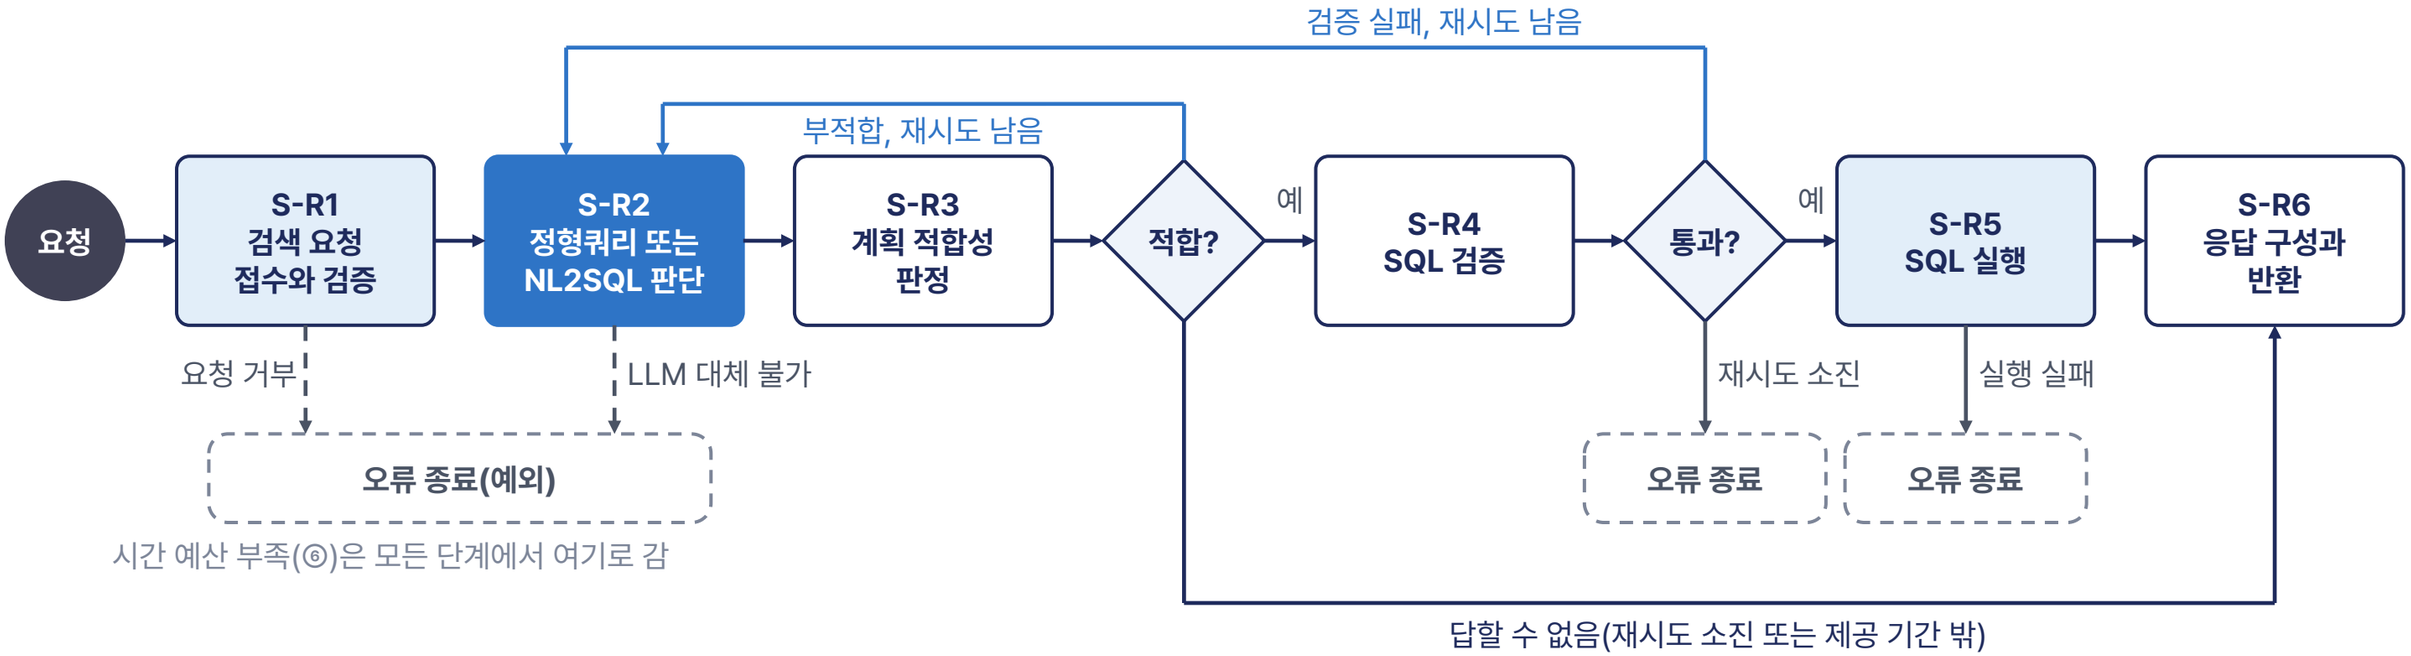
1. 순차: 앞 단계 출력이 뒤 단계 입력이라 차례대로 이어짐
2. 분기: S-R3은 계획이 맞는지, S-R4는 SQL이 규칙을 지키는지에 따라 경로가 하나로 갈림
3. 반복: 부적합 또는 검증 실패면 사유를 붙여 S-R2로 1회 되돌아감(사용자 결정 D-06, D-08)
4. 병렬 없음: 모든 단계가 앞 단계 결과를 써야 하므로 동시에 돌릴 단계가 없음

무단전재 및 배포 금지

① 흐름 도식

반복 구간 L-1은 S-R2 ~ S-R4이며, 그림의 오류 종료 두 곳에 예외 경로(점선)를 더해 그림

반복 구간 L-1: S-R2 ~ S-R4, 재시도 1회(위쪽 되돌림 화살표)



무단전재 및 배포 금지

① Mermaid 도식 스크립트

같은 흐름을 Mermaid 스크립트로도 남겨, mermaid.live에서 바로 고쳐 볼 수 있게 함

```
flowchart LR
    T((동기 요청)) --> R1[S-R1 검색 요청 접수와 검증]
    R1 --> R2[S-R2 정형쿼리 또는 NL2SQL 판단]
    R2 --> R3{S-R3 계획 적합성 판정}
    R3 -- 적합 --> R4{S-R4 SQL 검증}
    R3 -- 부적합, 재시도 남음 --> R2
    R3 -- 답할 수 없음 --> R6
    R4 -- 통과 --> R5[S-R5 SQL 실행]
    R4 -- 실패, 재시도 남음 --> R2
    R4 -- 실패, 재시도 소진 --> E1([오류 종료])
    R5 -- 성공 --> R6[S-R6 응답 구성과 반환]
    R5 -- 실패 --> E2([오류 종료])
    R1 -. 요청 거부 .-> E0([오류 종료 예외])
    R2 -. LLM 대체 불가 .-> E0
```

보는 방법

1. mermaid.live/edit 접속
2. 왼쪽에 스크립트 붙여넣기
3. 오른쪽 위 전체보기 아이콘으로 확인

시간 예산 부족(⑥)은 모든 단계에서 생길 수 있어 도식에서는 E0 하나로 묶음

무단전재 및 배포 금지

② S-R1 검색 요청 접수와 검증 (개요와 데이터)

요청을 받자마자 형식을 검사하고, 외부 LLM으로 나가기 전에 개인 식별자를 가림

단계 개요

단계ID	S-R1
단계명	검색 요청 접수와 검증
이전 단계	트리거
비즈니스 목표	잘못된 요청과 없는 회원을 처음에 걸러, 뒤 단계의 LLM 비용과 시간을 아낌
담당자 유형	규칙기반 코드
외부시스템	없음(시스템 내부 DB)
비고	이름처럼 정규식으로 못 잡는 식별자는 남을 수 있음(위험 항목 R-04). 회원ID는 이후 LLM에 보내지 않음

입력 데이터(출처: 트리거)

필드	타입	필수 여부	설명
request_id	string	필수	호출 추적 ID
question	string	필수	상담사 질문 원문. 1 ~ 500자
member_id	string	필수	상담 중인 회원ID
base_date	date	선택	조회 기준일. 없으면 lab_metadata의 데이터 기준일

출력 데이터

필드	타입	필수 여부	설명
request_id	string	필수	입력 그대로
masked_question	string	필수	개인 식별자를 [가림]으로 바꾼 질문
masked_count	integer	필수	가린 개수
member_id	string	필수	세션 변수 전용. LLM에 보내지 않음
base_date	date	필수	확정 기준일
coverage_start	date	필수	거래 제공 시작일
started_at	datetime	필수	워크플로우 시작 시각. 남은 시간 계산 기준
attempt	integer	필수	계획 시도 횟수. 0으로 시작

무단전재 및 배포 금지

② S-R1 검색 요청 접수와 검증 (수행 작업과 예외 처리)

형식 검사, 식별자 가림, 회원 확인을 차례로 하고, 실패하면 바로 오류를 돌려줌

수행 작업

1. started_at을 기록하고 남은 시간 예산을 측정함(⑥). 기준 미달이면 착지 단계로 감
2. 필수 필드 검사: question 1 ~ 500자, member_id 형식 M- + 숫자 4자리(설계 가정), base_date 형식 YYYY-MM-DD
3. 개인 식별자 가림: 정규식으로 전화번호, 카드번호(숫자 15 ~ 16자리), 주민등록번호, 이메일, 회원ID 패턴을 [가림]으로 바꾸고 개수를 셈 (사용자 결정 D-07)
4. 읽기 전용 트랜잭션을 열고 statement_timeout을 남은 시간 예산 이하로 둔 뒤, public.lab_metadata에서 데이터 기준일과 거래 제공 시작일을 읽음(키 이름은 개발 시 확인)
5. 세션 변수 3개(app.member_id, app.base_date, app.coverage_start)를 set_config(이름, 값, true)로 지정하고 app_internal.member_basic에서 회원이 있는지, 가입일이 기준일 이전인지 확인한 뒤 트랜잭션을 끝냄
6. attempt를 0으로 두고 출력 데이터를 만듦

예외 처리

- 필드 누락, 형식 오류, 500자 초과, 기준일이 데이터 기준일보다 뒤 → INVALID_REQUEST(400)로 오류 종료
- 회원 없음 또는 기준일에 아직 가입 전 → MEMBER_NOT_FOUND(404)로 오류 종료
- DB 접속 또는 조회 실패 → DB_ERROR(500)로 오류 종료
- 시작 전 남은 시간 예산 부족 → TIME_BUDGET_EXCEEDED(504)로 오류 종료

무단전재 및 배포 금지

② S-R2 정형쿼리 또는 NL2SQL 판단 (개요와 데이터)

LLM이 정형쿼리로 답할지, SQL을 새로 만들지를 정해 계획(plan) 하나로 돌려줌

단계 개요

단계ID	S-R2
단계명	정형쿼리 또는 NL2SQL 판단
이전 단계	S-R1 검색 요청 접수와 검증, S-R3 계획 적합성 판정(부적합 시), S-R4 SQL 검증(실패 시)
비즈니스 목표	검사된 정형쿼리를 먼저 써서 정확도를 지키고, 정형쿼리로 못 답하는 질문만 NL2SQL로 넓힘
담당자 유형	생성형AI + 규칙기반 코드(LLM 실패 시 키워드 규칙)
외부시스템	Groq LLM API(C-01)
비고	반복 구간 L-1의 시작 단계. 시스템 프롬프트 전문은 이 스크립트 부록 A

입력 데이터

필드	타입	필수 여부	출처와 설명
masked_question	string	필수	S-R1
base_date	date	필수	S-R1
coverage_start	date	필수	S-R1
attempt	integer	필수	첫 회 S-R1, 되돌아오면 S-R3 또는 S-R4
retry_reason	string	선택	S-R3 또는 S-R4. 첫 회 없음
previous_sql	string	선택	S-R4. 검증에 실패한 SQL

출력 데이터

필드	타입	필수 여부	설명
plan	object	필수	route, query_id, sql, target_views, requested_period, reason. 구조는 커넥터 응답 데이터 구조
plan_source	string	필수	LLM 또는 KEYWORD_RULE
attempt	integer	필수	1 늘린 값

무단전재 및 배포 금지

② S-R2 정형쿼리 또는 NL2SQL 판단 (수행 작업과 예외 처리)

LLM 호출은 5초 안에 끝내고, 실패하면 키워드 규칙으로 정형쿼리를 고르는 대체 경로로 감

수행 작업

1. 남은 시간 예산을 측정함(⑥). 기준 미달이면 착지(키워드 규칙 대체 경로)
2. attempt를 1 늘림
3. 유저 프롬프트를 조립함(masked_question, base_date, coverage_start, attempt, retry_reason, previous_sql). member_id는 넣지 않음
4. C-01을 호출함: timeout 5초, SDK max_retries 0, response_format json_schema strict
5. 응답 JSON을 plan으로 읽고 plan_source를 LLM으로 둠

예외 처리

- 타임아웃, 연결 오류, 429(요청 한도 초과), 5xx, 400 → 재시도 없이 대체 경로: 부록 「정형쿼리 목록」의 키워드 규칙으로 정형쿼리 1개를 골라 plan(route FIXED)을 만들고 plan_source를 KEYWORD_RULE로 둠
- 키워드 규칙에도 맞는 정형쿼리가 없음 → LLM_UNAVAILABLE(503)로 오류 종료
- LLM이 답을 거절함(refusal) → route UNANSWERABLE 계획으로 S-R3에 넘김
- 429의 retry-after는 기록만 하고 기다리지 않음(시간 예산 보호)

무단전재 및 배포 금지

② S-R3 계획 적합성 판정 (개요와 데이터)

계획이 실제로 실행할 수 있고 데이터 제공 기간 안인지 규칙으로 판정함

단계 개요

단계ID	S-R3
단계명	계획 적합성 판정
이전 단계	S-R2 정형쿼리 또는 NL2SQL 판단
비즈니스 목표	쓸모없는 SQL 검증과 실행을 막고, 답할 수 없는 질문은 빨리 "답할 수 없음"으로 알림
담당자 유형	규칙기반 코드
외부시스템	없음
비고	기간 판정 기준은 뷰 정의(04 ~ 06 SQL)에서 가져옴. 데이터 제공 기간 밖이면 다시 계획해도 바뀌지 않아 재시도 안 함

입력 데이터

필드	타입	필수 여부	출처
plan	object	필수	S-R2
plan_source	string	필수	S-R2
attempt	integer	필수	S-R2
base_date	date	필수	S-R1
coverage_start	date	필수	S-R1

출력 데이터

필드	타입	필수 여부	설명
verdict	string	필수	FIT, UNFIT, UNANSWERABLE 중 하나
candidate_sql	string	선택	FIT일 때 검증할 SQL
sql_source	string	선택	FIXED 또는 NL2SQL
query_id	string	선택	정형쿼리ID
retry_reason	string	선택	UNFIT 사유
unanswerable_reason	string	선택	답할 수 없는 이유

무단전재 및 배포 금지

② S-R3 계획 적합성 판정 (수행 작업과 예외 처리)

적합하면 S-R4, 부적합이면 S-R2로 1회 되돌리고, 답할 수 없으면 S-R6으로 보냄

수행 작업

1. 남은 시간 예산을 측정함(⑥)
2. route가 UNANSWERABLE이면 verdict UNANSWERABLE(사유는 plan.reason)
3. route가 FIXED이면 query_id가 FQ-01 ~ FQ-08 중 하나인지 확인하고, 등록된 SQL을 candidate_sql로 둠
4. route가 NL2SQL이면 sql이 비어 있지 않은지, target_views가 허용 뷰 7개 안인지 확인함
5. requested_period가 있으면 대상 뷰의 제공 기간(월 집계 6개월, 일별 90일, 연체 이력 12개월) 안이고 기준일 이전인지 확인. 밖이면 verdict UNANSWERABLE(데이터 제공 기간 밖)
6. 다음 단계 결정: FIT → S-R4 / UNFIT이고 attempt 1 → S-R2 / UNFIT이고 attempt 2 → UNANSWERABLE로 바꿔 S-R6 / UNANSWERABLE → S-R6

예외 처리

- plan 필드 누락(구조화 출력이라 드묾) → UNFIT으로 처리
- 3, 4번 확인 실패 → UNFIT, retry_reason에 사유 코드(예: UNKNOWN_QUERY_ID, VIEW_NOT_ALLOWED)
- 오류 종료 없음: 재시도를 다 써도 "답할 수 없음" 정상 응답으로 끝냄 (사용자 결정 D-08)

무단전재 및 배포 금지

② S-R4 SQL 검증 (개요와 데이터)

LLM이 만든 SQL은 이 검사를 통과하기 전에는 절대 실행하지 않음

단계 개요

단계ID	S-R4
단계명	SQL 검증
이전 단계	S-R3 계획 적합성 판정(FIT)
비즈니스 목표	허용한 뷰, 컬럼, 함수만 읽는 SELECT 한 문장만 통과시켜 데이터 유출과 DB 부담을 막음
담당자 유형	규칙기반 코드
외부시스템	없음
비고	정형쿼리도 같은 검사를 거침(이중 안전장치). 검증 규칙 전체는 부록 「SQL 검증 규칙」

입력 데이터

필드	타입	필수 여부	출처
candidate_sql	string	필수	S-R3
sql_source	string	필수	S-R3
query_id	string	선택	S-R3
attempt	integer	필수	S-R2

출력 데이터

필드	타입	필수 여부	설명
validated_sql	string	필수	검증을 통과하고 LIMIT을 맞춘 SQL
row_limit	integer	필수	결과 행 상한 200
retry_reason	string	선택	검증 실패 사유 코드
previous_sql	string	선택	검증에 실패한 SQL. LLM 재생성 참고용

무단전재 및 배포 금지

② S-R4 SQL 검증 (수행 작업과 예외 처리)

문자열 비교가 아니라 문법 트리로 검사하고, 행 상한을 강제로 붙임

수행 작업

1. 남은 시간 예산을 측정함(⑥)
2. PostgreSQL 문법 파서로 SQL을 문법 트리로 바꿈(라이브러리는 개발 시 선택, 예: sqlglot 또는 pglast)
3. 문장이 하나이고 SELECT(WITH 포함)인지 확인
4. 참조한 모든 표가 허용 뷰 7개(app. 스키마)인지 확인
5. 컬럼이 그 뷰의 컬럼 목록 안인지, 함수가 허용 함수 목록 안인지 확인
6. 금지 구문(쓰기, 여러 문장, 주석, FOR UPDATE, SELECT INTO, 금지 함수) 검사
7. LIMIT이 없으면 LIMIT 200을 붙이고, 200보다 크면 200으로 낮춤

예외 처리

- 검사 실패 + sql_source NL2SQL + attempt 1 → 사유와 직전 SQL을 담아 S-R2로 되돌아감(L-1)
- 검사 실패 + attempt 2 → SQL_VALIDATION_FAILED(422)로 오류 종료
- 검사 실패 + sql_source FIXED → 정형쿼리 등록 오류이므로 SQL_VALIDATION_FAILED(422)로 오류 종료하고 운영 알림
- 오류 메시지에는 SQL, 뷰 이름, 컬럼 이름을 넣지 않음(사유 코드는 로그에만)

무단전재 및 배포 금지

② S-R5 SQL 실행 (개요와 데이터)

읽기 전용 트랜잭션 안에서 회원 세션 변수를 걸고 실행해, 그 회원의 행만 읽음

단계 개요

단계ID	S-R5
단계명	SQL 실행
이전 단계	S-R4 SQL 검증(통과)
비즈니스 목표	검증된 SQL을 회원 범위 안에서 시간 예산 안에 실행해 답의 근거 데이터를 얻음
담당자 유형	규칙기반 코드
외부시스템	없음(시스템 내부 DB)
비고	DB 조회 시간은 최악값 합계에 넣지 않고 여유 4초 안에서 실측으로 확인. FQ-08은 실행 계획 비용이 커 실측 필수

입력 데이터

필드	타입	필수 여부	출처
validated_sql	string	필수	S-R4
member_id	string	필수	S-R1
base_date	date	필수	S-R1
coverage_start	date	필수	S-R1
started_at	datetime	필수	S-R1

출력 데이터

필드	타입	필수 여부	설명
columns	array	필수	컬럼 이름과 타입 목록
rows	array	필수	결과 행. 최대 200행
row_count	integer	필수	결과 행 수
truncated	boolean	필수	행 상한 200에 닿았는지
db_elapsed_ms	integer	필수	DB 실행 시간

무단전재 및 배포 금지

② S-R5 SQL 실행 (수행 작업과 예외 처리)

세션 변수, 읽기 전용, 실행 제한 시간, 행 상한 네 가지를 매번 실행 직전에 지정함

수행 작업

1. 남은 시간 예산을 측정함(⑥). 기준 미달이면 착지(안전 종료)
2. 커넥션 풀에서 sql_retriever_user 접속을 받음
3. BEGIN READ ONLY로 읽기 전용 트랜잭션을 시작함
4. SET LOCAL statement_timeout을 그 시점 남은 시간 예산 이하(밀리초, 내림)로 지정함
5. set_config('app.member_id', member_id, true), app.base_date, app.coverage_start를 지정함(트랜잭션 안에서만 유효)
6. validated_sql을 실행하고 최대 200행을 받음
7. ROLLBACK으로 끝내 세션 변수를 함께 지우고 커넥션을 돌려줌

예외 처리

- 실행 제한 시간 초과 → DB_TIMEOUT(504)로 오류 종료
- 그 밖의 DB 오류 → DB_ERROR(500)로 오류 종료
- 결과 0행은 오류가 아님(그 회원에게 해당 데이터가 없음) → S-R6로 감
- 세션 변수를 빼먹으면 행 수준 보안 때문에 0행이 나옴 → 0행이 잦으면 세션 변수 지정 누락을 먼저 의심

무단전재 및 배포 금지

② S-R6 응답 구성과 반환 (개요와 데이터)

결과 또는 "답할 수 없음"을 같은 응답 형식으로 돌려주고, SQL과 회원ID는 응답에 넣지 않음

단계 개요

단계ID	S-R6
단계명	응답 구성과 반환
이전 단계	S-R5 SQL 실행, S-R3 계획 적합성 판정(답할 수 없음)
비즈니스 목표	호출자가 바로 답변에 쓸 수 있는 근거 데이터와 안내 문장을 한 형식으로 넘김
담당자 유형	규칙기반 코드
외부시스템	없음
비고	종료 처리 시간 1초 안에서 수행. 응답 필드 영문명은 부록 「필드 영문명」

입력 데이터

출처	필드
S-R1	request_id, started_at, base_date, coverage_start
S-R2	plan_source, attempt
S-R3	verdict, sql_source, query_id, unanswerable_reason
S-R5	columns, rows, row_count, truncated, db_elapsed_ms(답할 수 없음이면 없음)

출력 데이터(호출자 응답)

필드	타입	필수 여부	설명
request_id	string	필수	요청 추적 ID
status	string	필수	OK 또는 UNANSWERABLE
route	string	선택	FIXED 또는 NL2SQL
query_id	string	선택	정형쿼리ID
plan_source	string	필수	LLM 또는 KEYWORD_RULE
columns	array	필수	컬럼 이름과 타입 목록
rows	array	필수	결과 행
row_count	integer	필수	결과 행 수
truncated	boolean	필수	행 상한 도달 여부
base_date	date	필수	조회 기준일
coverage_start	date	필수	거래 제공 시작일
message	string	필수	상담사에게 보여 줄 한 줄 안내
elapsed_ms	integer	필수	전체 처리 시간

무단전재 및 배포 금지

② S-R6 응답 구성과 반환 (수행 작업과 예외 처리)

정해진 문장 틀로 안내를 만들고, 감사 로그를 남긴 뒤 반환함

수행 작업

1. 남은 시간을 측정함. 종료 처리 시간 1초를 미리 떼어 두었으므로 기준 미달이어도 실행함
2. verdict가 UNANSWERABLE이면 status UNANSWERABLE, 아니면 OK
3. message를 문장 틀로 만듦: "기준일 {base_date} 기준 {row_count}건" / 200건 도달 시 "앞 200건만 보여 줌" / 0건 시 "해당 데이터 없음" / 답할 수 없음 시 사유
4. 응답 JSON을 구성함(SQL 문장, 회원ID, 내부 뷰 이름은 넣지 않음)
5. 감사 로그 기록: request_id, route, query_id, plan_source, attempt, elapsed_ms, row_count(질문은 가린 문장만, 회원ID는 해시값)
6. HTTP 200으로 반환

예외 처리

- 응답 구성 또는 직렬화 실패 → INTERNAL_ERROR(500)로 오류 종료
- 감사 로그 기록 실패 → 응답은 그대로 반환하고 로그 실패만 따로 알림(응답을 막지 않음)

무단전재 및 배포 금지

③ 외부시스템 연동 명세

외부 연동은 Groq LLM 1개뿐이며, 최악값은 5초 × (1 + 0) = 5초임

단계ID	외부시스템	연동 유형	커넥터ID	타임아웃	재시도	최악값	초과 시 처리
S-R2	Groq LLM API(openai/gpt-oss-120b)	LLM	C-01	5초(설계 가정)	0	5 × (1 + 0) = 5초	대체 경로로 계속(키워드 규칙 정형쿼리)

초과 시 처리 검토 순서와 판단 이유

1. 부분결과로 계속: 불가. 계획(SQL) 없이는 실행할 것이 없어 품질이 낮은 결과도 낼 수 없음
2. 대체 경로로 계속: 채택. 정형쿼리 8개는 LLM 없이 키워드 규칙으로도 고를 수 있음(부록 「정형쿼리 목록」)
3. 안전 종료: 키워드 규칙에도 맞는 정형쿼리가 없을 때만 LLM_UNAVAILABLE(503)로 끝냄

재시도 0회 이유: 재시도 역할은 반복 구간 L-1의 1회가 맡음. 연동 재시도까지 두면 최악값이 15초 예산을 넘음

DB는 시스템 내부 구성요소라 이 표에 넣지 않음(사용자 결정)

무단전재 및 배포 금지

④ 반복 구간 명세

계획 부적합 또는 SQL 검증 실패면 사유를 붙여 S-R2부터 1번 더 돌고, 최악값은 10초임

반복구간ID	비즈니스 목표	단계ID	재시도	최악값	착지 단계
L-1	계획이 적합하고 SQL이 검증을 통과할 때까지 계획을 1번 다시 만듦	S-R2 ~ S-R4	1	(5 + 0 + 0) × (1 + 1) = 10초	S-R3 부적합 → S-R6(답할 수 없음), S-R4 실패 → 오류 종료(SQL_VALIDATION_FAILED)

반복구간 L-1 (재시도 1회)
S-R2: 외부 연동 최악값 5 × (1 + 0) = 5초
S-R3: 외부 연동 없음(규칙 처리 시간은 여유 몫) → 0초
S-R4: 외부 연동 없음(규칙 처리 시간은 여유 몫) → 0초
구간 최악값 = (5 + 0 + 0) × (1 + 1) = 10초

착지 단계 판단 이유

1. S-R3 부적합 착지: 부분결과로 계속. 오류가 아니라 "답할 수 없음"이라는 정상 응답으로 S-R6에서 끝냄
2. S-R4 실패 착지: 안전 종료. 검증을 못 통과한 SQL은 실행하지 않는다는 원칙 때문에 부분결과와 대체 경로가 없음

무단전재 및 배포 금지

⑤ 워크플로우 명세

최악값 합계 10초는 전체 시간 예산 15초 안에 들고, 남는 5초를 종료 처리와 DB 조회 몫으로 씀

항목	값
워크플로우ID	W-1
이름	SQL 검색기
비즈니스 목표	상담사가 통화 중에 회원 데이터 근거를 바로 받아, 추측 없이 정확하게 답할 수 있게 함
전체 시간 예산	15초
종료 처리 시간	1초
최악값 합계	S-R1 0초 + L-1 10초 + S-R5 0초 + S-R6 0초 = 10초 (≤ 15초)
재개 방안	해당없음(조회만 하고 바깥에 반영하는 작업이 없어 처음부터 다시 해도 문제없음)

[최악값 합계]
반복구간 밖 단계: S-R1 0초, S-R5 0초, S-R6 0초 (외부 연동 없음)
반복구간 최악값: L-1 10초
분기: S-R3 → S-R6(답할 수 없음) 경로는 S-R4, S-R5를 건너뛰어 가장 큰 경로(S-R1 → L-1 → S-R5 → S-R6)를 씀
최악값 합계 = 0 + 10 + 0 + 0 = 10초 ≤ 15초 → 통과

[여유 시간]
15 - 10 = 5초 = 종료 처리 1초 + DB 조회와 규칙 처리 4초
DB 조회: S-R1 회원 확인, S-R5 SQL 실행
규칙 처리: 정규식 가림, 계획 판정, SQL 파싱
→ 4초 안에 드는지 개발 후 실측으로 확인

예산 조정 과정: 처음 안(LLM 타임아웃 5초, 재시도 1회)은 L-1 = (5 × 2) × 2 = 20초로 15초를 넘어, 연동 재시도를 0회로 줄이고 재시도 역할을 L-1에 맡김

무단전재 및 배포 금지

커넥터 목록

커넥터는 Groq LLM 1개이며, 제공자와 모델은 실행 설정으로 고르는 구조로 둠

커넥터 목록

ID	커넥터명	연동 방식	제공자
C-01	SQL 계획 생성 LLM	LLM	Groq(모델 openai/gpt-oss-120b, 개발사 OpenAI)

DB(PostgreSQL cardlab)는 시스템 내부 구성요소로 취급해 커넥터 목록에서 뺌(사용자 결정)

실행 설정으로 고르는 구조

1. SQL_RETRIEVER_LLM_PROVIDER = groq
2. SQL_RETRIEVER_LLM_MODEL = openai/gpt-oss-120b
3. API 키는 GROQ_API_KEY 환경변수로만 주입(코드, 이미지, 로그에 넣지 않음)
4. 제공자를 더하면 같은 응답 구조(부록 A의 JSON Schema)를 지키는 어댑터를 하나 더 만듦

출처: console.groq.com/docs/openai, /docs/model/openai/gpt-oss-120b (조사일 2026-10-15)

무단전재 및 배포 금지

C-01 LLM 명세: 모델과 하이퍼파라미터

값은 모두 Groq 공식 문서의 범위 안에서 정했고, 근거가 없는 수치는 설계 가정으로 표시함

항목	값	문서 범위 또는 근거
커넥터 ID	C-01	커넥터 목록
베이스 URL	https://api.groq.com/openai/v1	OpenAI 호환 문서
엔드포인트	POST /chat/completions	API Reference
인증	Authorization: Bearer $GROQ_API_KEY	API Reference
모델	openai/gpt-oss-120b	문맥 131,072, 최대 출력 65,536 토큰
temperature	0.2(설계 가정)	0 ~ 2, 기본 1
top_p	1(기본값, 바꾸지 않음)	0 ~ 1. temperature와 하나만 바꾸도록 권고
reasoning_effort	low(설계 가정)	low, medium(기본), high
include_reasoning	false	추론 문장을 응답에서 뺌
max_completion_tokens	4096(사용자 결정)	입력 + 출력 ≤ 문맥 길이
seed	42	결정적 샘플링은 최선 노력, 보장 안 함
response_format	json_schema, strict: true	gpt-oss-120b는 strict 지원
제한 시간과 재시도	timeout 5초, SDK max_retries 0	SDK 기본은 60초, 2회 재시도라 반드시 바꿈

주의

1. 출력 약 500 tps 기준 5초면 약 2,500 토큰까지임. 4096 상한까지 길게 쓰면 타임아웃(실측 필요)
2. 무료 플랜 표 기준 분당 8천 토큰이라 프롬프트 약 2,500 토큰이면 분당 3회 정도만 가능 → 계정 한도 확인 필요
3. logprobs, logit_bias, messages[].name은 넣으면 400 오류

출처: console.groq.com/docs/api-reference, /docs/reasoning, /docs/structured-outputs, /docs/rate-limits (2026-10-15)

무단전재 및 배포 금지

C-01 시스템 프롬프트 섹션별 요약

시스템 프롬프트는 프롬프트 가이드의 섹션 구조로 쓰고, 전문은 스크립트 부록 A에 둠

섹션	요약
[목표]	상담사 질문을 정형쿼리 선택 또는 PostgreSQL SELECT 한 문장 계획으로 바꿈
[역할]	카드사 정형 DB와 NL2SQL 경력 8년의 데이터 엔지니어. 허용 범위를 넘는 SQL은 만들지 않음
[맥락]	회원 범위는 DB가 세션 변수로 이미 거름. 기준일과 거래 제공 시작일이 정해져 있음
[입력]	공개 뷰 7개와 컬럼 설명, 정형쿼리 8개, 유저 프롬프트의 질문과 재시도 사유
[처리]	정형쿼리로 답할 수 있으면 FIXED 우선 → 아니면 NL2SQL → 뷰 범위 밖이면 UNANSWERABLE
[출력]	route, query_id, sql, target_views, requested_period, reason 6개 필드 JSON
[제약조건]	회원 조건과 세션 변수를 SQL에 쓰지 않음. app 뷰 7개와 허용 함수만, SELECT 한 문장
[예시]	정형쿼리 선택 1개, NL2SQL 1개, 답할 수 없음 1개

무단전재 및 배포 금지

C-01 유저 프롬프트와 응답 데이터 구조

유저 프롬프트는 XML 태그로 값을 감싸고, 응답은 strict JSON Schema로 6개 필드를 강제함

유저 프롬프트 변수

이름	타입	설명	필수 여부
question	string	가린 질문 (masked_question)	필수
base_date	date	조회 기준일	필수
coverage_start	date	거래 제공 시작일	필수
attempt	integer	몇 번째 계획인지(1 또는 2)	필수
retry_reason	string	앞 계획이 거절된 사유 코드	선택(첫 회 "없음")
previous_sql	string	검증에 실패한 SQL	선택(첫 회 "없음")

응답 데이터 구조

이름	타입	설명
route	string	FIXED, NL2SQL, UNANSWERABLE 중 하나
query_id	string 또는 null	FIXED일 때 FQ-01 ~ FQ-08
sql	string 또는 null	NL2SQL일 때 SELECT 한 문장
target_views	array(string)	읽으려는 뷰 이름(허용 뷰 7개 중)
requested_period	object	from, to(date 또는 null). 질문이 말한 기간
reason	string	판단 이유 한 문장(한국어)

strict 모드는 모든 필드가 required이고 선택 값은 null 허용 타입으로 둠(Structured Outputs 문서)

무단전재 및 배포 금지

⑥ 남은 시간 예산 정책: 측정 시점과 계산식

단계를 시작하기 전마다 실제로 흐른 시간을 재서, 남은 예산이 0.75초 이상일 때만 시작함

계산식

이름	계산식	이 워크플로우 값
남은 시간	전체 시간 예산 - 기존 사용 시간 - 종료 처리 시간	15 - 기존 사용 시간 - 1
남은 시간 예산	남은 시간 - SUM(앞으로 남은 단계의 외부 연동 최악값)	남은 시간 - (아래 차감값)
시작 기준 시간	전체 시간 예산 × 5%	15 × 0.05 = 0.75초
시작 조건	남은 시간 예산 ≥ 시작 기준 시간	남은 시간 예산 ≥ 0.75초

측정 시점별 차감값

측정 시점	차감하는 외부 연동 최악값
S-R1 시작 전	S-R2 5초 = 5초
S-R2 시작 전(1차, 재시도)	S-R2 5초 = 5초(반복 구간 안이라 1회분만)
S-R3, S-R4 시작 전(attempt 1)	되돌아갈 경로의 S-R2 5초 = 5초(분기 중 가장 큰 경로)
S-R3, S-R4 시작 전(attempt 2)	0초(더 돌아갈 일이 없음)
S-R5, S-R6 시작 전	0초

기존 사용 시간은 started_at부터 실제로 흐른 시간(측정값). S-R5는 statement_timeout을 이 시점 남은 시간 예산 이하로 둠

무단전재 및 배포 금지

⑥ 남은 시간 예산 정책: 계산 예와 착지 단계

느려진 요청은 LLM 재시도를 하지 않고 키워드 규칙으로 바꾸어 15초를 지킴

전체 시간 예산 15초 / 종료 처리 1초 / 시작 기준 0.75초
[예 1] S-R2 1차 시작 전, 기존 사용 0.4초
  남은 시간 = 15 - 0.4 - 1 = 13.6초
  남은 시간 예산 = 13.6 - 5 = 8.6초 ≥ 0.75 → 시작
[예 2] S-R2 재시도 시작 전, 기존 사용 6.2초
  남은 시간 = 15 - 6.2 - 1 = 7.8초
  남은 시간 예산 = 7.8 - 5 = 2.8초 ≥ 0.75 → 시작
[예 3] S-R2 재시도 시작 전, 기존 사용 9.6초
  남은 시간 = 15 - 9.6 - 1 = 4.4초
  남은 시간 예산 = 4.4 - 5 = -0.6초 < 0.75
  → 착지(키워드 규칙)
[예 4] S-R5 시작 전, 기존 사용 11.3초
  남은 시간 = 15 - 11.3 - 1 = 2.7초
  남은 시간 예산 = 2.7 - 0 = 2.7초 ≥ 0.75 → 시작
  statement_timeout = 2,700ms 이하

기준 미달 시 단계별 착지

단계	착지	판단 이유
S-R1	안전 종료 (TIME_BUDGET_EXCEEDED)	시작 직후라 실제로는 거의 없음
S-R2	대체 경로(키워드 규칙 정형쿼리) → 없으면 안전 종료	LLM 없이도 정형쿼리는 고를 수 있음
S-R3, S-R4	재시도를 끄고 차감값 0초로 다시 계산 → 그래도 미달이면 안전 종료	재시도 없이 끝날 수 있는 요청을 살림
S-R5	안전 종료 (TIME_BUDGET_EXCEEDED)	DB 결과 없이는 낼 결과가 없음
S-R6	착지 없음, 항상 실행	종료 처리 시간 1초를 미리 떼어 둠

무단전재 및 배포 금지

부록: 논리 뷰 목록

NL2SQL 계정이 읽을 수 있는 뷰는 9개이고, 그중 공개 뷰 7개만 LLM에 보여 주고 SQL에 허용함

뷰	담는 내용	컬럼 수	NL2SQL 허용
app.customer_profile	가입일, 연령대(기준일 이전 가입만)	2	허용
app.customer_cards	보유 카드(card_ref 가명 번호), 상품, 브랜드, 발급일, 상태, 연회비	9	허용
app.monthly_usage	카드별 월 승인 사용액과 건수, 최근 6개월	6	허용
app.merchant_usage	카드별 월별 가맹점, 업종 승인 사용액, 최근 6개월	10	허용
app.customer_delinquency	기준일 이전 완료월 중 가장 최근 연체 1건	5	허용
app.customer_delinquency_history	최근 완료월 기준 12개월 연체 이력	5	허용
app.customer_daily_usage	최근 90일 일별 승인 사용액과 건수(전체 카드 합)	3	허용
app_internal.customer_cards_full	원본 카드ID 포함 조립용 뷰	10	금지(위험 R-01)
app_internal.member_basic	회원ID, 가입일(S-R1 회원 확인 전용)	3	금지(서비스 코드만)

세션 변수 app.member_id(행 수준 보안), app.base_date, app.coverage_start를 트랜잭션 안에서 지정해야 행이 보임

근거: work/db_catalog.json(sql_retriever_user, 2026-10-15 실행), rdb/init/04 ~ 06 SQL

무단전재 및 배포 금지

부록: 정형쿼리 목록

정형쿼리 8개는 모두 NL2SQL 계정으로 EXPLAIN을 통과했고, LLM 실패 시 키워드 규칙으로도 고름

고정 조회ID	설명	결과 단위	대체 경로 키워드(설계 가정)	EXPLAIN
FQ-01	고객 기본 정보	회원 1행	가입일, 연령	통과
FQ-02	보유 카드 목록	카드 1장당 1행	보유 카드, 카드 목록, 연회비	통과
FQ-03	카드별 월 사용액(최근 6개월)	카드별 월 1행	카드별 + 월 또는 사용	통과
FQ-04	월 사용액 합계(전체 카드)	월 1행	월별, 월 사용, 지난달, 이번 달	통과
FQ-05	업종별 사용액(최근 6개월)	업종 1행	업종, 가맹점, 어디서	통과
FQ-06	최근 연체 현황	회원 1행	연체(이력 표현 없음)	통과
FQ-07	연체 이력(최근 12개월)	월 1행	연체 + 이력, 내역, 12개월	통과
FQ-08	일별 사용액(최근 90일)	일 1행	일별, 날짜별, 90일	통과(비용 큼, 실측 필요)

SQL 전문은 스크립트 부록 B. 키워드 규칙은 위에서부터 차례로 맞춰 처음 맞는 1개를 씀

근거: work/explain_fixed_queries.log(sql_retriever_user, 읽기 전용 세션, 2026-10-15)

무단전재 및 배포 금지

부록: SQL 검증 규칙

허용 목록에 있는 것만 통과시키는 방식(기본 거부)으로 검사함

허용

1. 뷰: app 스키마 7개(부록 논리 뷰 목록). 스키마 이름을 붙여 씀
2. 컬럼: 뷰마다 db_catalog.json의 컬럼 전체
3. 구문: SELECT 한 문장, WITH, WHERE, GROUP BY, HAVING, ORDER BY, LIMIT, 허용 뷰끼리의 JOIN, 서브쿼리
4. 함수: count, sum, avg, min, max, date_trunc, to_char, extract, coalesce, round, greatest, least, abs, 형변환
5. 결과 행 상한: LIMIT 200(없으면 붙이고, 크면 낮춤)

금지

1. 쓰기와 구조 변경: INSERT, UPDATE, DELETE, MERGE, CREATE, ALTER, DROP, TRUNCATE, GRANT, REVOKE, COPY
2. 여러 문장(;), 주석(-- 또는 /* */), FOR UPDATE 또는 FOR SHARE, SELECT INTO
3. 함수: set_config, current_setting, pg_로 시작하는 함수, generate_series, pg_sleep
4. 스키마: app_internal, public, pg_catalog, information_schema

사용자 결정 D-05(2026-10-15). DB 권한이 아니라 검사 규칙으로 막는 항목이 있으므로 위험 R-01 참고

무단전재 및 배포 금지

부록: 필드 영문명

단계 사이에 오가는 필드의 영문명과 한글 뜻을 한곳에 모음

영문명	한글 뜻	타입	처음 만드는 단계
request_id	요청 추적 ID	string	트리거
question	상담사 질문 원문	string	트리거
member_id	회원ID	string	트리거
masked_question	식별자를 가린 질문	string	S-R1
masked_count	가린 개수	integer	S-R1
base_date	조회 기준일	date	S-R1
coverage_start	거래 제공 시작일	date	S-R1
started_at	워크플로우 시작 시각	datetime	S-R1
attempt	계획 시도 횟수	integer	S-R1(0), S-R2(+1)
plan	LLM 계획	object	S-R2
plan_source	계획 출처(LLM 또는 키워드 규칙)	string	S-R2

영문명	한글 뜻	타입	처음 만드는 단계
verdict	계획 판정 결과	string	S-R3
candidate_sql	검증할 SQL	string	S-R3
sql_source	SQL 출처(정형쿼리 또는 NL2SQL)	string	S-R3
query_id	정형쿼리ID	string	S-R3
retry_reason	재계획 사유 코드	string	S-R3, S-R4
unanswerable_reason	답할 수 없는 이유	string	S-R3
validated_sql	검증 통과 SQL	string	S-R4
row_limit	결과 행 상한	integer	S-R4
previous_sql	검증 실패 SQL	string	S-R4
columns, rows, row_count, truncated, db_elapsed_ms	실행 결과	array, array, integer, boolean, integer	S-R5
status, route, message, elapsed_ms	응답 상태, 경로, 안내 문장, 전체 처리 시간	string, string, string, integer	S-R6

무단전재 및 배포 금지

부록: 오류 응답

오류 응답에는 SQL, DB 식별자, 접속 정보, 키를 넣지 않고, 다시 시도해도 되는지만 알려 줌

오류 코드	HTTP 상태	발생 단계	의미	다시 시도
INVALID_REQUEST	400	S-R1	필수 필드 누락, 형식 오류, 기준일 오류	아니요
MEMBER_NOT_FOUND	404	S-R1	회원이 없거나 기준일에 가입 전	아니요
LLM_UNAVAILABLE	503	S-R2	LLM 실패 + 키워드 규칙에도 맞는 정형쿼리 없음	예
SQL_VALIDATION_FAILED	422	S-R4	재생성 후에도 SQL이 검증 규칙 위반	아니요
DB_TIMEOUT	504	S-R5	실행 제한 시간 초과	예
DB_ERROR	500	S-R1, S-R5	DB 접속 또는 조회 오류	예
TIME_BUDGET_EXCEEDED	504	모든 단계 시작 전(⑥)	남은 시간 예산이 시작 기준 미달	예
INTERNAL_ERROR	500	S-R6	응답 구성 실패	예

{ request_id(string), status("ERROR"), error_code(string), message(string, 한국어 안내), retryable(boolean) }

메시지 예: "질문을 처리할 데이터 조회 문장을 만들지 못했습니다. 질문을 바꿔 다시 요청해 주세요."

무단전재 및 배포 금지

부록: 설계 점검표

설계 가이드 5절 점검표를 이 설계서에 그대로 대어 본 결과임

점검 항목	결과
단계ID 접두어가 트리거 유형(S-R)과 맞음	통과
입력과 출력이 필드 단위이고, 입력의 출처 단계가 그 필드를 출력함	통과
외부시스템이 "없음"이 아닌 단계(S-R2)가 연동 명세에 있음	통과
연동 명세의 커넥터ID(C-01)가 커넥터 목록에 있음	통과
연동 최악값 = 타임아웃 × (1 + 재시도)	통과(5 × 1 = 5초)
초과 시 처리와 착지를 부분결과 → 대체 경로 → 안전 종료 순서로 검토함	통과
반복 구간 최악값 = 구간 합계 × (1 + 재시도)	통과((5 + 0 + 0) × 2 = 10초)
최악값 합계에서 분기는 가장 큰 경로만 더함	통과
최악값 합계 ≤ 전체 시간 예산	통과(10초 ≤ 15초)
재개 방안이 해당없음 또는 단계별 결과 저장	통과(해당없음)
LLM 커넥터 필수 항목이 모두 채워짐	통과
시스템 프롬프트가 프롬프트 가이드 섹션 구조를 따름	통과(부록 A)

무단전재 및 배포 금지

부록: 설계 가정과 위험 항목

아래 항목은 개발 후 실측하거나 권한을 고쳐서 닫아야 함

설계 가정(실측으로 확인)

1. LLM 타임아웃 5초, temperature 0.2, reasoning_effort low
2. DB 조회와 규칙 처리가 여유 4초 안에 듦(특히 FQ-08)
3. 시작 기준 비율 5%(설계 가이드 기본값)
4. member_id 형식, 질문 500자 상한, 키워드 규칙표, lab_metadata 키 이름
5. 출력 4096 토큰 상한에서도 5초 안에 응답함

위험 항목

1. R-01: NL2SQL 계정이 app_internal 뷰 2개(원본 카드ID, 회원 ID)를 SELECT 할 수 있음 → 서비스용 계정과 NL2SQL 계정을 나누는 권한 정리 권장
2. R-02: NL2SQL 계정이 원본 테이블 public.lab_metadata를 읽을 수 있음(메타데이터라 영향 낮음)
3. R-03: Groq 무료 플랜 표 기준 분당 8천 토큰 → 실제 계정 한도 확인 필요
4. R-04: 이름처럼 정규식으로 못 잡는 식별자가 외부 LLM으로 나갈 수 있음

무단전재 및 배포 금지